



데이터분석기반 THMs 및 수도동파 분석

- AI 연구 프로세스 제안 -

2024. 07

AI연구센터 정지영

디지털기술을 활용한 기후위기 대응력 강화와 안정성 확보로 물안전·물복지 실현

* 정부는 VIP 지시에 따라 인공지능(AI) 디지털 기술 등을 활용한 스마트 물관리 추진 지시

기후변화, 극한홍수·가뭄 빈발 등 물관리 복잡성·불확실성 심화




앞으로 더한 위기

극한 강수량 ↑
- 21세기 후반기 최대 73%
(현재 배출추세 기준)


강수 편차 ↑
- 지역별·계절별 강수편차 심화
(21세기 중반기 남부지방 감소 가능성)

유역·하천관리




■ 홍수 발생 및 피해 규모 지속 증가

수도관리




■ 상수관로 노후도 및 누수사고 증가

수질관리



■ 100건/년 이상 수질 오염사고 발생

디지털 기술 지속 결합



■ 디지털전환 및 AI 관련 사업 증가 추세

◆ 추진배경 및 개요

- (배경) 대구·고령 수돗물 조사 결과, THMs 수질 기준이 초과되었다는 연구결과 및 언론보도('23.10)

2024. 10. 31 낙동강네트워크

“대구·고령 수돗물 발암물질 기준치 초과 검출 대책 촉구”


2024. 11. 01 MBC NEWS

“수돗물 발암물질 기준치 초과 대구·고령 문제없다 밝혔지만…”

- (추진) 환경부 “수돗물 수질현안 관련 사업 추진계획(안)” 관련 **소독부산물 가이드라인 구축 추진** (수도관리처)
- (목표) 실시간 계측 불가한 소독부산물 저감·관리를 위한 **정수장~공급과정 SI 기반 실시간 예측** 모델 개발

천연유기물(NOMs) + 염소 등 소독제 → THMs 등 소독부산물

구 분	소독부산물(THMs) 영향
반응물질	▣ NOMs 농도가 증가할수록 소독부산물 증가
소 독 제	▣ 주입률 및 접촉시간이 증가할수록 소독부산물 증가
수 질	▣ 수온 및 pH가 높을수록 소독부산물(THMs) 증가



❗ (유해성) 대표적 발암물질로 분류

IARC(국제암연구소) 기준 2B~3 그룹으로 분류

Group 2B : 인간에게 발암 가능성 있음, 동물실험에서는 발암성 확인됨 - 참고로 휴대폰 전자기장도 해당

Group 3 : 인체 발암성 미분류 물질


❗ (수질기준) 총트리할로메탄, 할로초산의 경우 주요 선진국과 비슷한 기준으로 설정

구분	한국	미국	일본	영국	캐나다	독일	호주	네델란드
THMs(mg/L)	0.1	0.08	0.1	0.1	0.1	0.05	0.25	0.025
HAAs(mg/L)	0.1	0.06	-	-	0.08	-	-	-

K-water 수질 목표

수자원공사
0.08
0.06

구 분		한강		낙동강 중류		낙동강 하류	
		K-water (고양 등 9개소)	서울시 (00개소)	K-water (고령)	대구시 (문산,매곡)	K-water (반송)	부산시 (덕산,화명)
잔류 염소		0.79	0.45	0.76	0.60	0.72	0.68
소독 부산물	THMs	0.017	0.021	0.035	0.022	0.039	0.028
	HAAs	0.008	0.003	0.005	0.005	0.014	0.002
	CH	0.001	0.004	0.001	0.002	0.004	0.001






광역(정) 평균 관말에서 39.7% 증가

* 자료출처 : 국가상수도 정보 시스템('17~'19년 월간 정수 검사 결과 평균값)

◆ 추진범위


고령정수장

- (현황) 낙동강 본류 취수, 고도정수처리(후오존+GAC) 운영
- (용량) 66천m³/일 (생활 26.2m³/일, 공업 39.8m³/일)



< 최근 6년 고령광역 정수 THMs 농도 >

< 최근 6년 고령광역 관말 THMs 농도 >



◆ 추진현황

추진경위

01 통계예측모델 구축 - 광역(정) 38개소 사업장
- (자체) 수질 및 운영자료 기반 다중회귀 분석 모델 수립

THMs(예측값) = pHa + 수온b + 유기물c + 염소주입률d + 체류시간e + ef
-검증결과 **정확도는 63%** 다소 낮고, TOC 기반 관리체계 필요


02 1차분석
- 데이터 탐색 + Decision Tree 알고리즘 활용 분석

	X								Y
	수온	pH	EC	NTU	TOC	염소주입률	체류시간	잔류염소	THMs
Case 1	●	●	●	●	●	●	●	●	●
Case 2	●		●			●		●	●
Case 3	●	●	●	●	●	●	●	●	●

- * (Case 1) 데이터 셋 전체 대상 독립변수와 종속변수 1:1 매칭 분석
- * (Case 2) 입력변수 Feature Importances 분석 후 중요 변수 대상 분석
- * (Case 3) THMs 발생 시계열 입력변수 사용 (T-1, T-2,


03 2차분석
- 추가변수 + 앙상블 알고리즘 적용 분석

입력변수 추가



I

1 단계



II

2 단계



◆ 분석 방법론

☑ 경험적 실험 중심으로 『3단계 전략』 분석 프로세스의 정립


Baseline 분석 단계
기본 분석 체계

1단계

알고리즘 중심의 분석

수질 항목과 연관된 최적 알고리즘과
매개변수 조정 등의 예측력 분석

- 활용할 수 있는 범위 내에서 최대의 데이터 수집 및 전처리 작업 후 데이터 고정
- 최적 모델을 찾기 위해 여러 가지 모델 적용
- 모델 하이퍼 파라미터 조정




심층분석 + 고도화 단계
설명력과 예측력 상승

2단계

양질의 데이터 중심의 분석

신뢰할 수 있고 효율적 방식으로
데이터를 개선하기 위한 프로세스

- 데이터 탐색과 일관성이 핵심
- 다양한 데이터 수집과 데이터 품질 향상 노력
- 알고리즘 코드는 고정 데이터 변화 중심




3단계

도메인 이론을 포함한 데이터 확장

데이터 불균형 해소를 위한 데이터
증강기법 적용

- 설명력 높은 양질의 데이터 생산
- 수문기상학적 불확실성 등을 고려한 변수간 복잡성 해소



개발 프로세스


방법론 확립을 위한 Case 별 실험

	X														Y
	수온	pH	EC	NTU	TOC	염소주입률	체류시간	잔류염소	혼화수	침전수	정수유입	정수유출	KMnO4	BOD	THMs
Case 1	●	●	●	●	●	●	●	●	●	●	●	●	●	●	●
Case 2	●		●			●		●	●	●			●		●
Case 3	●	●	●	●	●	●	●	●							●

* (Case 1) 데이터 셋 전체 대상 독립변수와 종속변수 1:1 매칭 분석


* (Case 2) 입력변수 Feature Importances 분석 후 중요 변수 대상 분석

* (Case 3) THMs 발생 시계열 입력변수 사용 (T-1, T-2,)




일시	수온	수소이온농도	전도도	탁도	중유기탄소	염소주입률	체류시간	혼화수	침전수	정수유입	정수유출	THMs
2013-01-31	3.3	7.6	290.3	1.7		3.6	1.6	1	0.2	0.77	0.63	
2013-02-01	3.4	7.6	287.6	1.7		3.6	1.5	0.99	0.21	0.76	0.62	
2013-02-02	3.4	7.6	288.3	5.3		3.7	1.6	1.01	0.2	0.78	0.65	
2013-02-03	2.9	7.7	291.4	5.7		3.5	1.4	1.11	0.26	0.77	0.66	
2013-02-04	3	7.6	289.3	4		3.5	1.5	1.08	0.26	0.77	0.66	
2013-02-05	3.2	7.6	291.8	4.4		3.5	1.5	1.03	0.23	0.78	0.66	0.018


Random Forest



GBM(Gradient Boosting Machine)



XGB(eXtra Gradient Boosting)



◆ 데이터 탐색

1. Data Variables (11년 ‘13~’23)

[1차 데이터]

Feature Name 분석데이터 항목	Data Duration 데이터 수집기간	Data Type 데이터 형	Description Feature정의	Unit 단위	Notes 내용 설명
측정일시	13.01.01 - 23.12.31	Date		Y-M-D	Index
THMs	13.01.02 - 23.12.06	Float64	정수, 실제분석값	mg/L	Month 단위
수온	13.01.01 - 23.12.31	Float64		℃	
수소이온농도	13.01.01 - 23.12.31	Float64			
전기전도도	13.01.01 - 23.12.31	Float64		μS/cm	
탁도	13.01.01 - 23.12.31	Float64			
총유기탄소	13.04.01 - 23.12.31	Float64		mg/L	
염소주입률	13.01.01 - 23.12.31	Float64	전 염소+중염소+후염소	hr	
체류시간	13.01.01 - 23.12.31	Float64	착수정유입-정수지 유출		
혼화수	13.01.01 - 23.12.31	Float64	공정수(잔류염소)		
침전수	13.01.01 - 23.12.31	Float64	공정수(잔류염소)		
정수유입	13.01.01 - 23.12.31	Float64	공정수(잔류염소)		
정수유출	13.01.01 - 23.12.31	Float64	공정수(잔류염소)		

[2차/3차 데이터]

Feature Name 분석데이터 항목	Data Duration 데이터 수집기간	Data Type 데이터 형	Description Feature정의	Unit 단위	Notes 내용 설명
일평균유량	13.01.01 - 23.12.31	Float64	공정수(TOC)	m3	Month 단위
체류시간(정수장)	13.01.01 - 23.12.31	Float64		hr	
다산 수온	18.01.01 - 23.12.31	Float64		℃	
원수	19.01.09 - 23.12.31	Float64		mg/L	
여과수	19.01.09 - 23.12.31	Float64		mg/L	
오존처리수	19.01.09 - 23.12.31	Float64		mg/L	
대표지	19.01.09 - 23.12.31	Float64		mg/L	
통합 GAC	19.01.09 - 23.12.31	Float64		mg/L	
정수	19.01.09 - 23.12.31	Float64		mg/L	
KMnO4	13.01.02 - 23.12.06	Float64		mg/L	
알칼리도	13.01.01 - 23.12.31	Float64			
정수수온	13.01.01 - 23.12.31	Float64			
혼화수pH	13.01.01 - 23.12.31	Float64			
BOD	13.01.02 - 23.12.06	Float64			Month 단위




- (2차) 유기물 및 TOC 등 기 연구사례의 도메인 정보를 반영한 THMs 영향 변수 추가 적용
- (3차) 2차 분석시 총유기탄소 계측 데이터의 신뢰성 낮음 확인에 따른 추가 변수 반영 / 정수의 TOC의 상관성은 높으나 데이터 부족

◆ 데이터 탐색

2. Data Availability

☑ 자동측정망(일간) 데이터 4017개~3283개, THMs(월간) 데이터 132개



◆ 데이터 탐색

3. Data Correlation


☑ 수온 > 전기전도도 > 혼화수pH > 정수유입 > 오존처리수 > 알카리도 순



4. Target Variable Example (Y ⇒ THMs)



☑ THMs 전체 데이터셋 통계값 : 0.005 ~ 0.075 / 평균 0.036

[THMs 전체]




count	132.000000
mean	0.036386
std	0.015204
min	0.005000
25%	0.024000
50%	0.036000
75%	0.047000
max	0.075000

[THMs 패턴 이상]



◆ 추진결과(1단계)

✓ 1차 분석 결과 (다중회귀보다 예측 결과는 높으나 부족 학습 데이터로 신뢰성은 낮고 목표(>0.8) 미달)




- 전체 데이터 활용 모델 적용시 R2 기준 0.71 ~ 0.77 유의미한 결과 ▶
- 변수 중요도 적용과 과거 데이터 적용 결과는 예상과 다른 결과 도출 ▶ 입력 변수의 확장 필요


◆ 추진결과(1단계)

✓ 2차 분석 결과 (결측치 보완 및 입력 변수 확장)


* (Case 1_1) 데이터 셋 전체 대상 독립변수와 종속변수 1:1 매칭 + KMnO4(주간) 추가 분석




K-NN Imputation 적용



R2 : 0.595
RMSE : 0.0091
MAE : 0.0071



R2 : 0.707
RMSE : 0.0077
MAE : 0.0056




R2 : 0.492
RMSE : 0.0102
MAE : 0.0082

- ✓ 1차 분석 비교시 낮은 예측력
- ✓ KMnO4(주간) 변수와 관계성 낮음
- ✓ 1차 분석 대비 학습 레코드 개수 줄어듦 (103개 → 101개)
- ✓ 학습 레코드 개수의 영향력이 큼

✓ 3차 분석 결과 (결측치 보완 + 입력변수 선택 + X일(T-X) 분석)

#	Column	Non-Null Count	Dtype
0	일시	4017 non-null	object
1	수온	4017 non-null	float64
2	수소이온농도	4016 non-null	float64
3	전기전도도	3912 non-null	float64
4	탁도	4016 non-null	float64
5	총유기탄소	3283 non-null	float64
6	염소주입량	4017 non-null	float64
7	체류시간	4017 non-null	float64
8	혼화수	4015 non-null	float64
9	침전수	4015 non-null	float64
10	정수유입	4015 non-null	float64
11	정수유출	4015 non-null	float64
12	kmno4	130 non-null	float64
13	THMs	132 non-null	float64



◆ 추진결과 종합(1단계)

	1차			2차			3차			통계	
	Case 1	Case 2	Case 3	Case 1_1	Case 2_1	Case 3_1	Case 1_2	Case 2_2	Case 3_2	Min	Max
GBM	0.778	0.669	0.5	0.595	0.699	0.77	0.610	0.54	0.74	0.5	0.778
RF	0.748	0.711	0.61	0.707	0.657	0.76	0.674	0.58	0.75	0.58	0.76
XGB	0.716	0.604	0.58	0.492	0.663	0.75	0.676	0.51	0.81	0.51	0.81
	0.747	0.661	0.563	0.598	0.673	0.76	0.653	0.543	0.766		

* 전처리 (결측치 보완) + 주요변수 + 시계열 분석 Case 3_2 목표치 달성

2단계 (정수장~배수지~관말) THMs 적용성 검토

[배수지] 개포통합

Feature Name 분석데이터 항목	Data Duration 데이터 수집기간	Data Type 데이터 형	Description Feature정의	Unit 단위	Notes 내용 설명
측정일시	13.01.01 - 23.12.31	Date		Y-M-D	Index
THMs	13.01.02 - 23.12.06	Float64	고령(정)	mg/L	Month 단위
잔류염소	13.01.01 - 23.12.31	Float64	개포통합(배)	mg/L	
감소율	13.01.01 - 23.12.31	Float64	정수유출 대비	%	
THMS.1	13.01.01 - 23.12.31	Float64	개포통합(배)	mg/L	단위 랜덤


[관말] 객기리 마을회관

Feature Name 분석데이터 항목	Data Duration 데이터 수집기간	Data Type 데이터 형	Description Feature정의	Unit 단위	Notes 내용 설명
수온	13.01.01 - 23.12.31	Float64		℃	
pH	13.01.01 - 23.12.31	Float64		hr	
잔류염소	18.01.01 - 23.12.31	Float64	객기리 마을회관	mg/L	
감소율	19.01.09 - 23.12.31	Float64	정수유출 대비	%	
THMS	19.01.09 - 23.12.31	Float64	공정수(TOC)	mg/L	

◆ 추진개요


☑ 수도사업장 공정감시용 CCTV 영상분석 시스템 구축

- (목표) AI 영상분석 기반 이상탐지로 위기대응 및 감시경보 고도화 추진 (약품투입 시범 도입)



- (사례) 운영시스템(iWater) 정상적인 투입 상황, 응집제 미투입 사고 금산(정) (22.05), 구미(정) (23.07) - 배관 불량, 밸브고장 등

◆ 추진개요



약품분배조의 약품투입 여부 분석 (투입/미투입 감지)



1. Ball 형



2. 원통형






3. 수레바퀴형



4. 낙하형

추진개요

- 01 Detection**
- 객체에 대한 판별 (물 감지)
- 02 Segmentation**
- 객체 영역 추출 (물 영역 추출)
- 03 Function**
- 홍수상황 또는 수위 기능 적용



◆ 분석 방법론

OpenCV (Open Source Computer Vision Library)




실시간 이미지 프로세싱에 중점을 둔 기술로 플랫폼, GPU 상관없이 인텔 CPU 환경에서 사용하는 라이브러리


Image Processing




Video, Stereo Processing




(**contour**) 동일한 색 또는 픽셀값(강도, intensity)을 가지고 있는 영역의 경계선 정보를 검출 > **외형을 파악**





(**Motion Detection**) 현재와 과거 프레임 사이의 픽셀마다 가지고 있는 RGB, Gray스케일 값비교 > **움직임을 판별**



(**absdiff**) 현재와 과거 프레임 사이의 픽셀의 프레임 차이가 있는 부분 검출 > **차이점 검출**





◆ 추진결과(프로토타입)



◆ 추진결과(시스템 반영)


CCTV 표준 프로토콜(RTSP) 지원 시 즉시 핵심알고리즘 적용이 가능토록 편의성과 효율성을 고려한 프로그램 자체개발

종합상황실(본사)	수지(정)	공주(정)	반송(정)	보령(정)	(본사, 종합상황실)			
					유역별 CCTV 연계	시뮬레이터 및 DB구축	운영 시스템 경보구축	iWater-CCTV연계 (이벤트발생시 표출)




◆ 추진개요 및 경위

- ☑ (배경) 겨울철 수도 **계량기 동파** 매년 발생 : 계량기 교체 비용, 누수, 단수 등 사회적 문제 발생



- ❖ `22. 11 : 계량기함내 온도 예측 모델 개발(1차)
 - 수도계량기 동파위험정보서비스 개시
- ❖ 신규 데이터 추가 및 IoT온도센서 설치 지역 확대에 의한 고도화 필요
- ❖ `23. 9 : 수도계량기함 내부 온도 예측모델 고도화(2차) 및 개선
- ❖ `23. 12 : IoT온도센서(100개) 추가 설치



* 국가상수도 정보 시스템 수도계량기 동파위험정보

추진방법

1차 (미계측 지역 가상 센서 개념의 동파 예측)

유역	한강	금강	낙동강	영섬	합계
지자체	5	4	8	5	22
서비스	25	20	40	25	110



(문제점) 기존 모델 test 데이터 예측 성능 대비 `22년 동절기 신규 취득 데이터 적용시 예측 성능 저하 발생

▪ (데이터) 1차('21.11~'22.2) 14만개 + 신규 취득 데이터('22.11~'23.2) 30만개

(해결방안) 추가 학습 데이터 반영 & 새로운 영향 인자 등 검토 → 모델 개선



• 과거 기온 연속 데이터 추가 (1일전~6일전) : 동파는 연속으로 6일 이상 영하일때 발생 확률 ↑, 수온 데이터 반영

구분	제공항목	수집기간	수용가수	데이터수
무선 온도센서 (IoT 센서)	① 모델 A : 기본항목	'21.11~'22.02 '22.11~'23.02	140	515,184
	② 모델 B : 기본항목 + 양지, 음지, 보온재유무			
	③ 모델 C : 기본항목 + 양지, 음지, 보온재유무 + 수온		109	351,576
SWM	④ 모델 D :기본항목	'22.11~'23.02	30,058	62,238,548

* 기본항목 : 검침일시, 지자체, 수용가 번호, 단말기 일련번호, 위도, 경도, 고도, 기온, 강수량, 습도, 풍속, 계량기함 온도

◆ 분석 결과


R ²	Random Forest	XGBoost	AdaBoost	Gradient Boosting	LightGBM	CatBoost
모델A	0.924	0.819	0.293	0.668	0.776	0.790
모델B	0.924	0.817	0.343	0.677	0.778	0.792
모델C	0.935	0.850	0.295	0.639	0.798	0.812
모델D	0.86	0.65	0.27	0.49	0.59	0.60



- 모델C(+수온)의 경우, R2: 0.935로 기본모델(A, B) 대비 높았으며, 신규 데이터('22 동절기) 적용시 오차수준 감소
- 모델A의 경우, 영향력이 낮은 범주형 데이터(음양지, 보온재 여부)를 제외하고도 현행 데이터 수준에서 효과적 예측 가능
→ 데이터 적용 규모(학습 및 추론시간)과 예측 정확성을 종합적으로 고려하여
국가상수도정보시스템(www.waternow.go.kr)에 적용

 도메인이 누락된 데이터 중심의 분석과 기초적 데이터 전처리 과정 / 데이터 왜곡

- 최대한 많은 종류 데이터 활용하면 예측력 높일 수 있다 **NO** → 추론에 불필요한 데이터 학습
- 데이터의 오결측 부분은 무조건 채워야 한다 **NO** → 노이즈 데이터의 생성으로 데이터 전체를 망치는 결과



D : DAY	팔당댐저수량	D : DAY	청평댐저수량 (백만m3)	청평댐방류량 (CMS)
LWM : Last Week Mean		LWM : Last Week Mean		
20131221	236.445	20190919	136.764	48.083
20131222	233.231	20190920	138.207	151.458
20131223	233.231	20190921	137.13	124
20131224	233.231	20190922	136.801	97.958
20131225	233.865	20190923	141.796	0.000
20131226	233.193	20190924	144.261	73.708
20131227	233.909	20190925	147.912	73.625
20131228	233.193	20190926	150.65	72.625
20131229	232.090	20190927	152.554	78.875
20131230	232.862	20190928	153.414	44.167
20131231	233.909	20190929	149.671	147.375
20140101	233.909	20190930	142.263	248
20140102	233.909	20191001	133.823	275.667
20140103	233.909	20191002	132.216	203.875
20140104	233.909	20191003	141.607	0.417
20140105	233.909	20191004	145.984	38.875
20140106	233.579	20191005	149.279	0
		20191006	151.239	0
		20191007	153.614	50.792

Backfill





Zero

D : DAY LWM : Last Day Mean	팔당댐저수량	팔당댐 방류량	팔당댐 방류량 (평균)	팔당댐체류시간 (DAY)
20131106	233.193	193.642	212.560	13.938
20131107	233.193	213.760		12.626
20131108	232.476	214.617		12.537
20131109	231.308	203.091		13.182
20131110	232.090	181.731		14.781
20131111	231.589	192.404		13.931
20131112	231.589	218.886		12.246
20131113	229.224	12.939	178.884	205.043
20131114	233.579	162.870		16.599

Sum


[한계점] 모델 중심의 AI 개발방식 추구

✓ AI 시스템은 코드와 데이터로 구성되지만, 코드(알고리즘) 개선 중심 분석



✓ 인공지능의 한계 ▶ AI 응용 상용화 80~87% 실패의 원인

- 실세계의 조잡하고 적은 양의 데이터로 방대한 신경망을 학습
- 분석을 통해 어느정도 유의미한 결과를 도출하는 것에 대한 함정에 빠진다
- 부족한 데이터를 이용한 결과 → 신규 데이터 입력시 급격히 결과가 낮아지는 현상이 발생



경청해 주셔서 감사합니다.

☑ **데이터 중심의 인공지능 예측 및 분석 프로세스 정립 (Data-Centric)**

코드에 집중하는 대신 기업은 신뢰할 수 있고 효율적이며 체계적인 방식으로 데이터를 개선하기 위한 체계적인 엔지니어링 프로세스 개발하는데 집중해야 한다.
즉 기업은 모델 중심 접근 방식에서 데이터 중심 접근 방식으로 전환해야 한다.

- Andrew Ng, LandingAI CEO 겸 설립자



Model-Centric		Data-Centric
• 활용할 수 있는 범위 내에서 최대의 데이터 수집 • 최적 모델을 찾기 위해 여러 가지 모델을 적용 • 모델 하이퍼파라미터 조정 • 초기 전처리 작업 후 데이터 고정	Model-Centric Data-Centric AI = Focus on Code + Focus on Data shift in focus	• 데이터 일관성이 핵심 • 다양한 데이터 수집과 데이터 품질 향상 노력 투자 • 다양한 모델 적용 • 알고리즘/코드는 고정 • 데이터 품질 고려

☑ **단계 구분(자료수집 ➡ 전처리 ➡ 모델개발 ➡ 최적화 ➡ 배포) 및 분야별 상세화 접근**

단 계	자료 수집·이해	자료 전처리	AI 모델 구축	데이터/모델 튜닝	배포·운영
절 차	필요 정보 수집 및 EDA	오결측 제어 및 처리	모델 선정 및 구현	데이터 확장 및 모델 최적화	후처리 및 배포

수치 요약과 시각화를 사용하여 데이터를 탐색하고 변수 간 잠재적 관계를 도출




(필요성) 문제의 잠재적인 근본 원인을 찾도록 유도해줄 수 있는 단서와 통찰력 탐색

EDA 분석 항목
• 데이터 개별 속성값 관찰
• 데이터 오. 결측 필터링
• 통계 값 활용

분석 내용
전체적인 추세를 분석하여 각 속성값의 범위와 분포를 벗어난 값에 대한 원인 분석과 해당 속성값 활용에 대한 의사결정
누락 값이나 이상치 값에 대한 의미 파악
적절한 통계 지표(Summary statistics) 사용 (평균/중앙값/최빈값/범위/분산 등)


(단 계) 전체 파악 → 개별 속성 관찰 → 속성 간의 관계 순으로 분석



Variables


(고유값 분포 등 디테일 정보)

통합 분석




barplot (multi)

개별 분석



barplot


관계 분석




countplot

missing values

(결측치 및 결측 기간 등)



missingno




plot (single label)




plot (multi label)

Correlations


(변수간 관계성 파악)



heatmap




distplot




interactions

Outliers


(변수의 분포)



violin plot



scatterplot







Boxplot

이상치 또는 이상값 탐지, 표준 또는 예상된 것에서 벗어나 구성된 데이터 셋 관찰

* 발생한 이벤트 또는 데이터 포인트를 식별

- ✓ **(품질향상)** 품질 이상을 식별하고 처리하면 노이즈와 오류를 줄여 실제 기본 패턴을 더욱 더 확실히 나타내도록 한다.
- ✓ **(의사결정)** 이상 징후를 식별하고 처리함으로써 신뢰성을 높이고 더 나은 정보에 입각한 결정으로 결과 개선
- ✓ **(학습성능)** 노이즈에 맞춰질 수 있는 성능저하 요소를 제거 함으로써 학습 모델의 성능 최적화하고 정확한 예측값을 제공



Case

(포인트) 데이터 셋 외부에 존재하는 개별 포인트로 오류, 잡음 또는 고유한 발생

(상황별) 특정 상황 내에서 표준에서 벗어나는 포인트로 반드시 이상치인 것으로 볼 수 없고 특정 맥락에서 볼 때 변칙적

(집단적) 개별 사례가 정상으로 보일 수 있더라도 함께 표준에서 벗어나는 일련의 데이터 영역에서의 이상 사례 포함

(시각화) 잠재적 이상값과 패턴을 신속하게 식별, 차트와 그래프를 사용하여 데이터를 구성하여 비정상적 포인트나 추세 검사

(통 계) 관찰된 데이터를 예상 분포 또는 패턴과 비교하여 이상 감지

☑ (학 습) 본 패턴을 학습한 다음 해당 패턴과 편차를 식별하여 데이터 이상 판별

Anomaly Detection

1. Model-based

Isolation Forest

One-Class SVM

2. Density/Distance-based

Gaussian Mixture Model

K-Nearest Neighbours

LOF

3. Reconstruction-based

PCA(Principal Component A)

Auto-Encoder

4. Deep Learning

DeepSVDD

PyOD(Python Outlier Detection)

Deep Embedded Clustering

TadGAN(Transformer-Based)

1. Supervised Learning

(장점) 양/불 판정 정확도가 높다
(단점) 비정상 Sample 취득하는데 시간과 비용소요

2. Semi-Supervised Learning


(장점) 정상 Sample로 학습이 가능하다
(단점) Supervised 대비 정확도가 떨어진다

3. UnSupervised Learning


(장점) Learning 과정이 필요하지 않다
(단점) 정확도가 낮으며, 모델 Hyper parameter 민감

Outlier(비지도학습)


IQR(사분위간 범위)





Seasonal(계절적 이상값)




PersistAD(지속적 이상값) - 시계열 임계값 초과나 미만의 편차



Seasonal(계절적 이상값)



이동평균과 표준편차를 이용한 이상값 식별 (기본 ↑, 상수 ↓)




Isolation Forest

무작위로 선택된 특징의 최대값과 최소값 사이의 분할값을 통해 이상 징후를 분리하는 앙상블 학습

(특징) 비정상 데이터는 루트 노드에서 가까운 깊이에서 고립, 정상은 먼 깊이에서 고립

(판별) Path length(x가 고립될 때까지 분할 횟수)를 기반으로 Anomaly score 정의하여 부여




Auto-Encoder(LSTM)

타임 스탬프 데이터를 사용한 패턴을 예측하고 과거 패턴과 일치하지 않는 현상 식별하는 신경망 기법

(특징) 데이터 Labeling을 하지 않아도 데이터의 주성분의 되는 정상 영역의 특징을 학습

(판별) 비정상적 sample 입력시 정상 sample 처럼 복원하기 때문에 차이가 발생하여 검출







TadGAN

복원, 이미지 생성 등에 특화된 GAN을 활용 패턴을 복원하며 학습하여 예측시 에러를 판단


(특징) 비지도 학습의 확장성 및 이식성 문제를 보완한 생성형기법은 최신의 기술로 효과 향상

(판별) 데이터를 기준으로 reconstructed data를 생성하여 차이를 계산하여 임계값 넘는 이상치 검색



☑ 데이터를 가치 있게 만드는 요인을 파악하고 신뢰할 수 있는 데이터 확보

- (방법) ① Raw ② 제거 ③ Mean/Median ④ Zero or Frequent ⑤ K-NN Imputation ⑥ MICE ⑦ Deep Learning
- 오결측 값이 다른 데이터와 관계가 있는지 확인 후 전통적 방식 또는 신규 방식의 선택 적용



Categorical Handling of Missing Data

1. RNN 기반 기법


- M-RNN
- GRU-D(Gated Recurrent Unit)
- BRITS(Bidirectional Recurrent Imputation for Time series)
- ODE-RNN(Ordinary Differential Equation)

2. GAN 기반 기법

- GAIN (Generative Adversarial Imputation Networks)
- NAOMI(Non-Autoregressive Multiresolution Sequence Impu)

3. 혼합 기법

- SAITS(Self Attention based)
- BRITS
- Transformer



K-NN Imputation 적용


☑ 누락 된 값을 대체하는 완벽한 방법은 없다. 데이터 유형에 따라 성능 높은 방법 선택

- 수자원 분야는 시공간적 연계성을 고려한 방식이 유효하나 처리 시간과 난이도를 고려


☑ 불균형 데이터란 정상 범부의 관측치 수와 이상 범주의 관측치 수가 현저히 차이나는 데이터

- (내용) 오염원 고농도 발생건수가 정상범위 보다 현저히 적어 학습에 의해 고농도 발생를 찾아내지 못할 수 있다.


Under Sampling




TomekLinks




- (장점) 다수 범주 데이터의 제거로 계산시간 감소
- (단점) 데이터 제거로 인한 정보 손실이 발생



Over Sampling



Synthetic Minority Oversampling Technique



- (장점) 대부분 언더 샘플링 보다 높은 분류 정확도
- (단점) 계산 시간 증가와 / 과적합 가능성 존재

☑ (개요) 해결 문제에 적용할 방법을 찾고자 하는 실무적 활용 퀵 가이드 구축

- “어떠한 데이터를 가지고 무엇을 할 것인가?” 라는 질문에서 시작

 (특징) Baseline 모델 : AI 기능 구축을 위한 Workflow 형식의 프레임워크

- **일방향 방식에서 ▶ 선택적 분석(Module & Function)과 피드백 분석 가능**

- 신규 기능 또는 알고리즘 반영의 유연함 → 레고 블록 조립식의 간단한 방식으로 확장 가능

구성요소

모듈/기능 : EDA, QC, Algorithm 파일 구분

샘플 : 기존 분석한 내용을 레퍼런스로 활용

Notebook : Anaconda, Google Colab, VSCode 등 컴파일러 방식

중요원칙

확장성


ChatGPT3 또는 개별로 만든 기능을 기존 모듈에 적용

반복성

모든 기능을 반복적으로 개별 수행 > 결과 확인



개방성

OpenSource 개념으로 서버/클라이언트 활용



✓ 개발의 생산성과 운영의 안정성을 최적화하기 위한 방법론 도입

- AI Life Cycle 전체 반영 (데이터와 인프라를 포함한 모든 시스템이 유기적으로 돌아가야 한다.)



Vertical
&
Agile
MLOps

MLOps= ML + DEV + OPS

