


범위 민감도를 도입한 도시 복잡시스템의 빅데이터 분석 방법론 연구

A framework for band-sensitive big data analysis for urban complex system

2024. 10. 07.

AI연구센터 류제완

Systemic thinking + AI



(Capra, F. 1996)




Fig. 1. Causal Loop Diagrams of Early Response for HNS Spill Accidents

(Ryu., et al., 2017)

1. Introduction
 - 1) 연구 배경 및 필요성
 - 2) 연구 목적 및 가설
2. Previous related studies
 - 1) 복잡한 시스템에 내재된 인과관계 정량화
 - 2) 클러스터링을 이용한 시계열 변수 선택 및 차원 축소
 - 3) 인공지능 기반 예측 모델과 손실 함수 설계
3. Band-sensitive big data analysis of urban complex system (BBAUCS)
 - 1) BBAUCS 설계
 - 2) 로렌츠 끌개를 이용한 검증
4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례
 - 1) 국내 미세먼지 현안 분석
 - 2) 서울시 미세먼지 농도의 인과관계 분석 및 변수 선택
 - 3) LSTM 모델을 이용한 미세먼지 농도 예측 및 범위 민감성 분석
5. Conclusion & Future research


Research outline	
문제인식 (필요성)	1. 도시 복잡시스템의 분석 및 관리에는 시스템적 관점의 접근이 필요하다. 2. 기존의 시스템 관점의 다양한 한계를 극복하기 위해 인공지능을 활용한 비선형 시계열 분석이 도입되었으나, 도시 복잡시스템 분석의 중요 요소들이 충분히 고려되지 않았다. (인과관계 기반 변수 선택, 시스템 관리 정책 고려)
가설설정	1. 도시 복잡시스템에서 인과관계를 고려한 변수 선택은 타겟 변수의 예측력 향상에 기여할 것이다. 2. 도시 복잡시스템의 변수 예측에서 타겟 변수의 범위에 따라 동적 가중치가 적용된 손실 함수의 도입은 특정 범위의 예측력을 선택적으로 강화시킬 것이다.
연구설계	1. 도시 복잡시스템 데이터 (Time series feature) 사이의 인과관계 정량화 2. 데이터간 인과관계의 유사성에 기반한 클러스터링 3. 인과관계 유사성 기반 변수선택 전후 예측모델(=LSTM)의 예측력 변화 확인 4. 타겟 변수의 범위에 따라 동적 가중치가 적용된 손실함수 도입 및 예측력 변화 확인 5. 시뮬레이션 데이터(Lorenz attractor) 활용한 방법론 적용 및 검증 6. Real-world data (2019년 미세먼지 계절관리기간)를 활용한 방법론 적용 및 검증
자료수집	1. Lorenz system의 시뮬레이션 데이터 생성 및 dummy feature 추가(random walk 및 time lagged feature) 2. 서울시 열린 데이터광장 등 시간단위 공공 데이터 이용 (기상요인, 대기오염물질, 교통량, 생활인구수)
자료분석	1. 시계열 데이터들의 인과관계 확인 (CCM 알고리즘의 correlation coefficient 확인) 2. SOM 클러스터링 확인 (U-matrix, heat map of allocated neurons) 3. 인과관계 패턴 기반 변수선택 도입 전후 LSTM 모델의 예측력 비교 (RMSE, MAPE) 4. Dynamically weighted loss function 도입 전후 LSTM 모델의 예측력 비교 (RMSE, MAPE)
가설검증	1. 모든 데이터를 사용하는 것보다 인과관계가 유사한 데이터만을 활용할 때, LSTM 모델의 예측력(RMSE, MAPE)이 향상되었다. 2. LSTM 모델의 손실 함수에 동적 가중치를 도입했을 때, 타겟 변수의 범위에 따른 예측력(RMSE in band, MAPE in band)이 선택적으로 향상되었다. 3. 예측 목표가 되는 변수의 값에 따라 서로 다른 가중치를 주었을 때, 목표 구간에 대한 예측력이 향상되는 것을 확인하였다.
결론	1. 복잡한 시스템의 분석에서 예측 모델의 예측력을 향상시키기 위해 시스템 변수 사이의 인과관계에 기반한 군집화 및 변수 선택을 적용할 수 있으며, weighted loss function의 도입으로 정책적 중요도가 높은 구간의 예측력을 향상시킬 수 있다.

1. Introduction

- 1) 연구 배경 및 필요성
- 2) 연구 목적 및 가설

1. Introduction: 연구 배경 및 필요성

- 지속적으로 증가하는 도시와 사회의 **복잡성**(complexity)은 **시스템적 관점**의 중요성을 강조함.
 - 피드백 구조 (feedback loop)
 - 비선형적 관계 (nonlinear relationship)
 - 파급 효과 (Cascading effect)
 - 창발 현상 (emergent behavior)
 - 초기 조건의 민감성 (sensitive to initial condition)




(Wilbanks, Fernandez, et al. 2014)




- 대규모 재난의 사례로부터 복잡성을 확인 가능
 - 1998년 캐나다 북동부 대규모 정전 사태
 - 얼음 폭풍으로 인한 전기 송전선의 파괴
 - 대규모 정전
 - 신호 체계 등 교통 시스템의 마비
 - 응급환자 수송의 어려움
- 도시의 인프라들은 독립적이지 않고, 서로 dependent 하다.
(Chang et al., 2007)

1. Introduction: 연구 배경 및 필요성



- 복잡한 시스템은 “계층적 구조”로 이루어진다 (NESTED system). (Tansely, 1935; Capra, 2005)


1. Introduction: 연구 배경 및 필요성



1. Introduction: 연구 배경 및 필요성


- 복잡한 시스템의 비선형 시계열 분석에 대한 딥러닝 알고리즘의 **구조적 유사성**.
 - SD 모델의 Stock-Flow Diagram과 회귀신경망(Recurrent Neural network)은 서로 대응 가능한 유사 구조.
 - Reservoir computing 등 Causal loop diagram과 유사한 구조를 지니는 알고리즘 사용.
 - *Field of study that gives computers the ability to learn without being explicitly programmed* (Samuel, A.L., 1959)
- 복잡한 시스템의 특성을 고려하지 않고, 단순히 뉴런 사이의 연결 강도가 요소 사이의 관계를 반영한다고 가정함.

SFD와 RNN 모델의 구조적 유사성




(Chen, Y. T., Tu, Y. M., & Jeng, B., 2011)

인과지도(CLD)와 ESN 모델의 구조적 유사성



(Abdelbari, H., & Shafi, K. (2017))



1. Introduction: 연구 배경 및 필요성

- (연구 아이디어) 복잡한 시스템의 특성이 충분히 고려된 딥러닝 분석 방법론의 개발이 필요
 - 복잡한 시스템 내부의 유의미한 변수 선별(하위 시스템 발견) ⇔ 딥러닝의 변수 선택(차원 축소)
 - 데이터의 특성에 적합한 딥러닝 모델의 구조를 그대로 채택하는 것이 타당함
 - 시스템 관리의 정책적 측면 고려 ⇔ 목적에 적합한 손실 함수의 도입 (Rengasamy, D., et al., 2020)



1. Introduction: 연구 가설 및 목적

- 연구 배경
 - 도시 복잡시스템의 분석에 시스템적 관점(비선형 시계열 분석)의 필요성 증가
 - 시스템적 관점과 딥러닝의 결합에서 복잡시스템의 특성이 충분히 고려되지 않음
- 연구의 필요성
 - 복잡시스템의 특성과 시스템 관리의 정책적 관점을 고려한 딥러닝 결합
- 연구가설
 - 도시 복잡시스템의 분석에서 하위 시스템을 고려하는 변수 선택은 타겟 변수에 대한 예측력을 향상시킬 수 있다.
 - **인과관계의 유사성에 기반한 변수 선택**은 타겟 변수에 대한 예측력을 향상시킬 수 있다.
 - 도시 복잡시스템의 분석에서 딥러닝 모델의 손실 함수를 통해 정책적 측면을 고려할 수 있다.
 - 타겟 변수의 범위에 따라 **동적 가중치가 적용된(범위 민감도) 손실 함수의 도입**은 특정 범위의 예측력을 선택적으로 강화시킬 수 있다.

2. Previous related studies

- 1) 복잡한 시스템에 내재된 인과관계 정량화
- 2) 클러스터링을 이용한 시계열 변수 선택 및 차원 축소
- 3) 인공지능 기반 예측 모델과 손실 함수 설계

2. Previous related research: 복잡한 시스템에 내재된 인과관계 정량화

- 두 변수 사이의 인과관계는 설명력(predictability)으로 정의됨 (Granger, 1969).
 - 인과관계 정량화의 두 변수 사이의 인과관계는 **과거로부터의 설명력**(predictability)으로 정의됨 (Granger, 1969).
 - If $\rho(X|Y)$ is high, X is causing Y. ($\rho(X|Y) < 1$)
 - 허위 상관관계(spurious correlation)의 제거 (고차원의 빅데이터 분석에서 특히 중요 (Fan, 2008))


$$X_t + b_0 Y_t = \sum_{j=1}^m a_j X_{t-j} + \sum_{j=1}^m b_j Y_{t-j} + \epsilon'_t$$
$$Y_t + c_0 X_t = \sum_{j=1}^m c_j X_{t-j} + \sum_{j=1}^m d_j Y_{t-j} + \epsilon''_t$$

인과관계 정량화 기법의 예시

Granger causality	Granger, 1969
Bayesian network inference	Eaton & Murphy, 2000
Transfer entropy	Schreiber, 2000
Convergent cross mapping	Sugihara., et al., 2012

- 다른 기법에 대한 CCM의 장점
 - 비선형적 시스템으로의 적용가능성
 - 연산량 감소
 - 인과성의 방향 구별

2. Previous related research: 복잡한 시스템에 내재된 인과관계 정량화



- 주어진 데이터에서 하위 시스템(계층적 구조)을 추론할 수 있음
 - 인과계수의 크기와 인과관계의 방향을 고려하여 하위 시스템을 추론할 수 있음 (Sugihara., et al., 2012)
 - 그러나, 인과관계의 강도에 대한 기준이 제시되지 않아 상대적인 비교만 가능함 (Chen, Z.Y., et al., 2017)

(Sugihara., et al., 2012)


2. Previous related research: 복잡한 시스템에 내재된 인과관계 정량화

- Convergent Cross Mapping(Sugihara et al., 2012)
 - 동일한 매개변수 t 를 갖는 다양한 변수들이 존재할 때, 이 변수들의 shadow manifold(=reconstruction)는 모두 일대일 대응이 되고 상호간에 추정(estimate)이 가능함. 이때, 추정값과 실제값의 상관계수가 두 변수간의 인과적인 설명력을 나타냄.
 - 알고리즘의 핵심 개념: X 와 Y 의 일대일 대응지점에서, X 의 이웃에서 얻은 weight로 Y 의 값을 Y 의 이웃으로부터 추정
→ 도시 복잡시스템의 **인과관계 정량화**에 적용 가능함

$$\hat{Y}(t)|M_X = \sum w_i Y(t_i, k) \quad \text{Estimate Y from neighbors}$$
$$w_i = u_i / \sum u_j$$

Get weight from X

$$u_i = \exp\left(-\frac{d[x(t), x(t_i)]}{d[x(t), x(t_1)]}\right)$$
$$\rho = \frac{\sum(Y - \bar{Y}) \sum(\hat{Y} - \bar{\hat{Y}})}{\sqrt{\sum(Y - \bar{Y})^2 \sum(\hat{Y} - \bar{\hat{Y}})^2}} \quad (\approx \text{Pearson correlation coefficient})$$



(Sugihara et al., 2012)

2. Previous related research: 클러스터링을 이용한 시계열 변수 선택 및 차원 축소


- Whole time clustering / subsequence clustering
 - 시계열 변수 각각을 **discrete object**로 취급
 - 다양한 알고리즘이 적용가능하며, 이때 시계열 데이터의 representation와 similarity(=distance) metric이 주요 이슈가 됨
- 인과관계를 고려한 feature selection에 클러스터링을 적용할 수 있음
- **시계열 데이터의 representation에 인과관계를 정량화하여 적용 가능**

시계열 데이터의 representation	Distance measurement	군집화 알고리즘	참고 문헌
Raw data	Euclidean distance	Fuzzy clustering	Policker and Geva (2000)
Wavelet transform	LCSS	Fuzzy c-means clustering	Aghabozorgi (2012)
PCA	spCA factor	Hierarchical clustering	Abonyi, Feil, Nemeth, and Arva (2005)
SAX	Euclidean distance and Kullback-Liebler distance	K-means clustering	T.W. Liao (2005)
Global characteristics	Euclidean distance	Self-organizing Map	X. Wang, Smith. And Hyndman, (2005)

2. Previous related research: 클러스터링을 이용한 시계열 변수 선택 및 차원 축소

- Self-organizing map (kohonen, 1982)
 - SOM 모델의 뉴런은 **고차원의 데이터 구조를 학습하여 2차원 지도에 투영**함
 - 클러스터에 대한 초기 정보(클러스터의 수 등) 없이 클러스터링이 가능함
 - 주어진 기준에 따라 인과계수의 기준에 따라 시계열 변수를 분류하는 것이 아니라, SOM 모델의 학습에 의해 **유사한 인과관계의 패턴을 갖는 변수들로 클러스터를 구성** 가능.

$$\begin{aligned}c &= \arg \min \|x(t) - m_i(t)\| \\m_i(t+1) &= m_i(t) + h_{ci}(t)[x(t) - m_i(t)], \quad \forall i \in neighborhood \\h_{ci}(t) &= \alpha(t) \exp(-\|c - i\|^2 / 2\sigma^2(x)), \quad 0 < \alpha(t) < 1\end{aligned}$$




(Mcld, 2010)

2. Previous related research: 클러스터링을 이용한 시계열 변수 선택 및 차원 축소

- Long Short-Term Memory neural network (Hochreiter, S., & Schmidhuber, J., 1997)
 - 순환신경망(RNN) 계열의 예측 모델. 장기 의존성 문제를 해결함.
 - 시계열 데이터의 예측에 매우 강력한 성능을 보이며 특히 미세먼지 농도 예측에 활발히 사용되고 있음 (Jiachen, et al., 2019; Xayasouk, T., Lee, H., & Lee, G., 2020).
 - 그러나, **시스템 관리 측면의 손실 함수**가 고려되지 않음.

$$l_{\text{KL}}(\tilde{\mathbf{y}}, \tilde{\mathbf{z}}) = \frac{1}{M} \sum_{m=1}^M \sum_i \tilde{z}_i^{(m)} \log \frac{\tilde{z}_i^{(m)}}{\tilde{y}_i^{(m)}} \quad (\text{to predict extreme event})$$



$$\text{forget gate: } f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$\text{input gate: } i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\text{input gate: } \tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$\text{cell state: } C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$\text{output gate: } o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$


$$\text{output gate: } h_t = o_t * \tanh(C_t)$$

3. Band-sensitive Big data Analysis of Urban Complex System (BBAUCS)

- 1) BBAUCS 설계
- 2) 로렌츠 끌개를 이용한 검증


3. BBAUCS: 방법론 설계

- 인과관계의 강도에 대한 기준 부재
 - 인과관계의 **상대비교**를 통해 해결
 - CCM을 통해 도출된 인과계수를 매트릭스 형태로 원 데이터 대체
 - 이를 SOM의 입력값으로 활용하여 학습
 - 다른 변수들에 대한 **인과관계의 패턴이 유사한 변수끼리 클러스터링**이 이루어짐.




3. BBAUCS: 방법론 설계

- MSE loss function에 Gaussian function을 변형시킨 형태의 가중치를 도입
 - 기존의 regression 문제는 대부분 loss function으로 MSE가 사용됨.
 - Gaussian 함수 형태의 가중치를 도입하여, 의도적인 trade-off를 발생시킴.
 - LSTM 모델이 weight의 업데이트에 특정 범위의 loss를 더 크게 받아들이도록 설계.
 - Symmetric, 밴드 중심으로 갈수록 강한 가중치, 파라미터의 조절을 통해서 섬세한 최적화가 가능.




$$\text{Gaussian weight} = \begin{cases} a \times \exp\left(-\frac{(x-b)^2}{2c^2}\right), & |x-b| - c\sqrt{2 \ln a} < 0 \\ 1, & |x-b| - c\sqrt{2 \ln a} \geq 0 \end{cases}$$

The type of loss function	a	b	c	RMSE	RMSE in fixed band	MAPE in fixed band
MSE	-	-	-	3.50 (0.19)	4.25 (0.23)	17.84 (1.50)
GW ¹	6	20	3.5	3.16 (0.16)	4.057 (0.274)	16.80 (1.15)
GW	6	20	5	3.12 (0.15)	3.98 (0.21)	16.57 (0.91)
GW	2	20	8	3.36 (0.33)	4.10 (0.43)	17.16 (1.96)
GW	6	20	8	3.08 (0.17)	3.96 (0.21)	16.37 (0.89)
GW	6	20	20	3.06 (0.11)	3.77 (0.17)	15.42 (0.68)
GW	2	20	20	3.39 (0.34)	4.25 (0.46)	17.73 (2.05)




그리드 서치 방식의 파라미터 최적화

3. BBAUCS: 방법론 설계




3. BBAUCS: 방법론 설계





3. BBAUCS: 방법론 설계

시계열 데이터 (T Length, N feature)




클러스터링에 따른 변수 선택



변수간 causality coefficient 분석


$$\begin{bmatrix} 1 & \cdots & \rho_{1n} \\ \vdots & \ddots & \vdots \\ \rho_{n1} & \cdots & 1 \end{bmatrix}$$

SOM 적용 및 변수 군집화



Weighted loss 도입

$\hat{y}$ y




3. BBAUCS: Lorenz attractor를 이용한 검증


- 로렌즈 끌개 (Lorenz attractor)
 - 피드백 구조를 포함하는 대표적인 복잡한 시스템인 로렌즈 끌개 시스템을 활용한 검증
 - [시스템 자체 변수 9개 + Random walk 변수 5개 + 의도적으로 서로 다른 time lag가 추가된 X, Y, Z] + 랜덤 노이즈

$$RW_i(t) = \sum_{j=1}^t V_j \text{ where } V_j = +1 \text{ or } -1 \text{ with equal probability}$$



X



Y



Z



Eqn. of Lorenz attractor

$$\begin{aligned} \text{net } \frac{dx}{dt} &= \sigma y - \sigma x \\ \text{net } \frac{dy}{dt} &= \rho x - \rho(y + z) \\ \text{net } \frac{dz}{dt} &= xy - \beta z \end{aligned}$$

3. BBAUCS: Lorenz attractor를 이용한 검증

- Hyperparameter는 trial-and-error를 통해 최적화
- 밴드는 임의로 설정됨 (b=25, 20~30)


hyperparameter for	window size	Time to predict	learning rate	Hidden node	layers	epoch
LSTM model	24	6	0.001	5	1	500
Gaussian parameters of weighed loss function	(a, b, c) = (3, 25, 12)					
Input to LSTM model	All features, Causal features of variable Z					
Output of LSTM model	Z					

- 사용된 성능지표
 - 20번의 학습-테스트를 통한 평균값 비교


$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$$

3. BBAUCS: Lorenz attractor를 이용한 검증

(SOM 결과에 따라 재배열)




P-matrix



각 뉴런에 할당된 변수의 수

U-matrix




이웃 뉴런까지의 평균 거리

Cluster 1: X, Y, lagged X, lagged Y, Inc.X, Inc.Y, Dec.X, Dec.Y

Cluster 2: Z, lagged Z, Inc.Z, Dec.Z

Cluster 3: RW1, RW2, RW3 → 클러스터링 결과가 시스템에 정의된 인과관계와 동일함을 확인

3. BBAUCS: Lorenz attractor를 이용한 검증



3. BBAUCS: Lorenz attractor를 이용한 검증

- 변수 Z와 함께 클러스터링된 변수를 LSTM 모델의 입력값으로 사용할때 테스트 셋 전체에 대한 예측력이 향상됨
- MSE에 gaussian weight를 적용했을 때 밴드 내부의 예측력이 향상됨
→ BBAUCS의 적용이 타겟 변수에 대한 예측력을 향상시키는 것을 확인함

	All features + MSE loss	Causal features + MSE loss	All features + Weighted MSE loss	Causal features + Weighted loss
RMSE	4.32 (2.26)	3.00 (1.31)	5.01 (1.99)	3.25 (1.72)
MAPE	20.85 (11.78)	14.39 (6.90)	24.39 (10.23)	15.49 (8.77)
RMSE in band	4.59 (2.70)	3.05 (1.61)	2.34 (0.71)	2.99 (2.11)
MAPE in band	28.92 (18.34)	19.62 (10.96)	7.68 (2.51)	7.85 (5.35)

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

- 1) 국내 미세먼지 현안 분석
- 2) 서울시 미세먼지 농도의 인과관계 분석 및 변수 선택
- 3) LSTM 모델을 이용한 미세먼지 농도 예측 및 범위 민감성 분석

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

- 머신러닝 기법의 강력한 성능을 활용한 미세먼지 농도 예측 연구는 매우 활발하게 이루어지고 있음.
- Task는 대부분 미세먼지 농도의 regression이며, RNN 계열의 neural network를 사용함.
- 미세먼지의 영향인자로 대기오염물질과 기상정보를 함께 다루는 것이 일반적임.
- 기존의 연구들은 모델의 전체적인 성능 향상에 주력함


→ 미세먼지의 경우 등급이 나누어지는 농도가 존재하므로, 상대적으로 중요하지 않은 매우 낮거나 매우 높은 농도의 예측력을 trade-off하여 등급이 나누어지는 구간의 예측이 더욱 정확해질 수 있다면 정책적으로 중요한 의미가 있음.

Target	사용된 neural network	참고 문헌
2일 후 최대 농도	Elman Network	Brunelli et al. (2006)
다음 step의 농도	Echo State Network	Xu, X., & Ren, W. (2019)
다음 6시간의 농도	Long Short-Term Memory (LSTM)	Jiachen et al. (2019)
다음 10일간의 농도	LSTM and Deep Autoencoder	Xayasouk, T., Lee, H., & Lee, G. (2020)



4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

- 기존의 연구들은 regression task에 알맞은 loss function(MSE)을 사용.
→ Real-world 사례에 대한 정책적 중요도 고려가 필요.
 - 국내 미세먼지의 사례
 - 2018년 3월 미세먼지 등급 ‘나쁨’ 및 ‘매우 나쁨’ 을 구분하는 농도 기준 대폭 강화
 - 2018년 7월 미세먼지 주의보 및 경보 발령 기준 대폭 강화
 - 도시 외부 및 내부 요소 모두에 영향을 받음
 - 국내 상황을 반영하지 못한 수치모델(기상청) 기반 예보
 - 외부요인과 내부요인의 복잡한 상호작용
- 미세먼지 이슈에 대한 현상적인 관점에서, 발령 기준 근처의 예측 정확도 향상이 특히 필요함

▶초미세먼지 예보기준(일평균) 강화



4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례



- 대기질 및 미세먼지 측정 지점
- 교통량 수집 지점

- 2019년 계절관리기간 사례 선정 (2019년 12월 ~ 2020년 3월)
- 자료의 개방 여부, 측정 위치의 변경, 초장기 결측치 등으로 데이터 이용이 제한적
- 대기오염물질, 기상요인, 교통량, 생활인구수
- 19680 × 54 data
- 에어코리아, 기상자료개방포털, 서울시열린데이터광장을 통해 수집
- R, Python (google colab pro 환경)


4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

데이터명	단위	출처
서울시 교통량 (올림픽대로, 상행)	대	서울시 교통정보 시스템(TOPSIS)
서울시 교통량 (올림픽대로, 하행)	대	서울시 교통정보 시스템(TOPSIS)
서울시 교통량 (강변북로, 상행)	대	서울시 교통정보 시스템(TOPSIS)
서울시 교통량 (강변북로, 하행)	대	서울시 교통정보 시스템(TOPSIS)
서울시 생활인구수	명	서울 열린데이터광장
서울시 기온	℃	기상청 기상자료개방포털
서울시 습도	%	기상청 기상자료개방포털
서울시 강수량	mm	기상청 기상자료개방포털
서울시 풍속	m/s	기상청 기상자료개방포털
서울시 일사량	MJ/m ²	기상청 기상자료개방포털
인천광역시 기온	℃	기상청 기상자료개방포털
인천광역시 습도	%	기상청 기상자료개방포털
인천광역시 강수량	mm	기상청 기상자료개방포털
인천광역시 풍속	m/s	기상청 기상자료개방포털
인천광역시 일사량	MJ/m ²	기상청 기상자료개방포털
천안시 기온	℃	기상청 기상자료개방포털
천안시 습도	%	기상청 기상자료개방포털
천안시 강수량	mm	기상청 기상자료개방포털
천안시 풍속	m/s	기상청 기상자료개방포털
천안시 일사량	MJ/m ²	기상청 기상자료개방포털
백령도 기온	℃	기상청 기상자료개방포털
백령도 습도	%	기상청 기상자료개방포털
백령도 강수량	mm	기상청 기상자료개방포털
백령도 풍속	m/s	기상청 기상자료개방포털
서울시 이산화황(SO ₂) 농도	ppm	한국환경공단 에어코리아
서울시 이산화질소(NO ₂) 농도	ppm	한국환경공단 에어코리아
서울시 일산화탄소(CO) 농도	ppm	한국환경공단 에어코리아


데이터명	단위	출처
서울시 오존(O ₃) 농도	ppm	한국환경공단 에어코리아
서울시 미세먼지(PM ₁₀) 농도	ppm	한국환경공단 에어코리아
서울시 초미세먼지(PM _{2.5}) 농도	ppm	한국환경공단 에어코리아
성남시 이산화황(SO ₂) 농도	ppm	한국환경공단 에어코리아
성남시 이산화질소(NO ₂) 농도	ppm	한국환경공단 에어코리아
성남시 일산화탄소(CO) 농도	ppm	한국환경공단 에어코리아
성남시 오존(O ₃) 농도	ppm	한국환경공단 에어코리아
성남시 미세먼지(PM ₁₀) 농도	ppm	한국환경공단 에어코리아
성남시 초미세먼지(PM _{2.5}) 농도	ppm	한국환경공단 에어코리아
파주시 이산화황(SO ₂) 농도	ppm	한국환경공단 에어코리아
파주시 이산화질소(NO ₂) 농도	ppm	한국환경공단 에어코리아
파주시 일산화탄소(CO) 농도	ppm	한국환경공단 에어코리아
파주시 오존(O ₃) 농도	ppm	한국환경공단 에어코리아
파주시 미세먼지(PM ₁₀) 농도	ppm	한국환경공단 에어코리아
파주시 초미세먼지(PM _{2.5}) 농도	ppm	한국환경공단 에어코리아
인천광역시 이산화황(SO ₂) 농도	ppm	한국환경공단 에어코리아
인천광역시 이산화질소(NO ₂) 농도	ppm	한국환경공단 에어코리아
인천광역시 일산화탄소(CO) 농도	ppm	한국환경공단 에어코리아
인천광역시 오존(O ₃) 농도	ppm	한국환경공단 에어코리아
인천광역시 미세먼지(PM ₁₀) 농도	ppm	한국환경공단 에어코리아
인천광역시 초미세먼지(PM _{2.5}) 농도	ppm	한국환경공단 에어코리아
백령도 이산화황(SO ₂) 농도	ppm	한국환경공단 에어코리아
백령도 이산화질소(NO ₂) 농도	ppm	한국환경공단 에어코리아
백령도 일산화탄소(CO) 농도	ppm	한국환경공단 에어코리아
백령도 오존(O ₃) 농도	ppm	한국환경공단 에어코리아
백령도 미세먼지(PM ₁₀) 농도	ppm	한국환경공단 에어코리아
백령도 초미세먼지(PM _{2.5}) 농도	ppm	한국환경공단 에어코리아

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

P-matrix



(백령도 대기오염물질 전체, 그 외 지역 오존 농도)를 제외한 대기오염물질들이 클러스터 ①에 할당됨





* SOM 결과에 따라 컬럼 순서를 재배열

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

클러스터 1	서울 이산화황 농도, 서울 일산화탄소 농도, 서울 이산화질소 농도, 서울 미세먼지 농도, 서울 초미세먼지 농도 , 성남 이산화황 농도, 성남 일산화탄소 농도, 성남 이산화질소 농도, 성남 미세먼지 농도, 성남 초미세먼지 농도, 파주 이산화황 농도, 파주 일산화탄소 농도, 파주 이산화질소 농도, 파주 미세먼지 농도, 파주 초미세먼지 농도, 인천 이산화황 농도, 인천 일산화탄소 농도, 인천 이산화질소 농도, 인천 미세먼지 농도, 인천 초미세먼지 농도
클러스터 2	서울 오존 농도, 성남 오존 농도, 파주 오존 농도, 인천 오존 농도
클러스터 3	서울 교통량 (올림픽대로, 상행), 서울 교통량 (올림픽대로, 하행), 서울 교통량 (강변북로, 상행), 서울 교통량 (강변북로, 하행), 서울 생활인구수, 서울 강수량, 인천 강수량, 천안 강수량, 백령도 강수량, 서울 풍속, 인천 풍속, 천안 풍속, 백령도 풍속, 백령도 이산화황 농도, 백령도 일산화탄소 농도, 백령도 이산화질소 농도, 백령도 미세먼지 농도, 백령도 초미세먼지 농도
클러스터 4	서울 온도, 인천 온도, 천안 온도, 백령도 온도, 서울 습도, 인천 습도, 천안 습도, 백령도 습도, 서울 일사량, 인천 일사량

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례



- 각 데이터가 SOM 모델의 활성화 정도를 나타냄

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

- Trial-and-error를 통한 Hyperparameter 최적화 결과
- Training : validation : test = 6 : 1.5 : 2.5

hyperparameter for LSTM model	window size	learning rate	Hidden node	layers	epoch
	36	0.0005	7	1	early stopping rule
Gaussian parameters of weighed loss function	(a, b, c) = (9, 75, 10)				
Input to LSTM model	All features, Causal features of PM2.5				
Output of LSTM model	PM2.5				

- 성능지표
- 20번의 학습-테스트를 통한 평균값 비교

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad \text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$$

4. BBAUCS 사례 적용: 2019년 서울 미세먼지 고농도 사례

- 서울시 초미세먼지 농도와 함께 클러스터링된 변수를 LSTM 모델의 입력값으로 사용할때 테스트 셋 전체에 대한 예측력이 향상됨
 - MSE에 gaussian weight를 적용했을 때 밴드 내부의 예측력이 향상됨
- real-world data에 대해서 BBAUCS의 적용이 타겟 변수 예측력을 향상시키는 것을 확인함

	All features + MSE loss	Causal features + MSE loss	All features + Weighted loss	Causal features + Weighted loss
RMSE	10.23 (0.48)	9.47 (2.19)	13.60 (1.83)	10.36 (0.96)
MAPE	60.05 (7.67)	43.84 (7.52)	76.26 (17.33)	64.66 (9.21)
RMSE in band	12.83 (2.18)	17.21 (8.59)	11.05 (2.93)	10.14 (2.61)
MAPE in band	13.92 (2.84)	20.25 (11.25)	12.32 (3.72)	11.47 (3.56)

5. Conclusion & Future research

5. Conclusion & Future research

- BBAUCS가 도시 복잡시스템의 타겟 변수에 대한 예측력을 향상시키는 것을 확인함
 - CCM, SOM, dynamically weighted loss function이 도입된 LSTM 모델을 통합한 BBAUCS는 도시 복잡시스템의 데이터에서 인과관계의 패턴이 유사한 데이터를 선택할 수 있으며, LSTM 모델을 이용한 예측력 향상이 가능함.
 - CCM과 SOM을 이용한 변수 선택이 타겟 변수의 예측력(RMSE, MAPE)을 향상시키는 것을 확인함.
 - Dynamically weighted loss function이 특정 범위의 예측력(RMSE in band, MAPE in band)을 선택적으로 향상시키는 것을 확인함.
- 여러 환경 및 재난 관리에서 정책적으로 중요한 기준(공기질, 수질 등)이 정해져 있는 경우 기준값 근처의 예측력을 선택적으로 향상시킨 예측 tool로서 의사결정지원 가능
 - 특히, 단기 예측 모델이 필요한 경우 활용 가능
 - 다양한 분야에 걸친 공편익을 기대 가능
- 연구의 한계점 및 향후 연구를 통한 보완
 - 데이터 수집 센서의 한계점: 불연속적인 측정값(SO₂, CO)
 - 방법론이 적용가능한 도시 복잡시스템의 정량적 정의 필요
 - 데이터 분포(고왜도 데이터 등)에 따른 방법론 적용 결과 비교

5. 연구의 한계점 및 첨언

- “시스템적 관점”에서 “AI 기반 분석” 방법론 개발 수행 → AI 분석에 집중한다면...
 - 충분한 컴퓨팅 리소스가 주어진다면, 변수 선택이 과연 유의미한가? 허위 상관관계의 제거가 반드시 필요한가?
 - SHAP 등 model-agnostic한 X-AI 분석 기법이 상당히 발전됨
 - 결국 중요한 것은 데이터의 양과 질
- 방법론 자체보다는 연구 과정의 경험이 현 시점에서 더 많은 도움이 되고 있음
 - AI 분석의 전 과정
 - CCM, DTW 등
 - Python(Pytorch), R
- 실무 기여 방안?

감사합니다.